项目作品集 · AI AGENT BENCHMARK

blockblast-bench

复刻 Block Blast!（8×8 方块消除）游戏机制的**确定性评测环境**，让大模型与经典算法同台对局，量化评测 LLM 的**空间规划、长程决策与指令遵循**能力。

GitHub：github.com/kittimzhe/blockblast-bench（MIT 开源） | 在线报告：kittimzhe.github.io/blockblast-bench

0	107	6	10140	2×CI	100%
第三方依赖	自动化测试	Agent 梯度	单局最高分	Python 3.9/3.13	确定性复现
纯标准库	四层金字塔	random→beam→LLM	beam-80 · 1004 步	全绿	同种子=同牌序

1 为什么做这个项目

现有 LLM 基准大多测知识与代码，**缺少可复现、可量化的「空间规划 + 长程决策」评测**。Block Blast! 恰好是一个规则极简但策略深度极高的载体：放错一块，几十步后才暴露恶果。

- **确定性公平**——同一种子 = 同一牌序，所有 Agent 面对完全相同的发牌，分差只来自决策质量；
- **梯度化参照系**——random / greedy / heuristic / beam 四级经典基线，把 LLM 的成绩「放进刻度尺」解读；
- **失败也是数据**——非法落子不视为 bug，而是「指令遵循」的测量对象（反馈重试 + 非法率指标）；
- **全链路可观测**——每局完整转录 → 决策质量分析 → GIF 回放 → HTML 报告，败局可逐帧归因。

Python 3.9+ | 零依赖设计 | LLM Agent | Beam Search | inspect_ai | GitHub Actions CI | GIF89a 手写编码器 | GitHub Pages | pytest 不变量/模糊测试

游戏机制（忠实复刻）

- 8×8 棋盘，托盘 3 块**全部用完才补发**；方块不可旋转/翻转（19 种形状库）；
- 整行/整列同时消除，连续消除累积 combo 倍率，全清 +300；
- 剩余方块无处可放即终局；计分为可配置的近似复刻（+1/格、行分 10/30/60…、combo 封顶 ×4、全清 +300）。

评测协议

- 默认种子集 2024–2033 共 10 局，所有 Agent 同集对比；
- LLM 观测：坐标标注文本棋盘 + 托盘小图；动作：`{"piece","row","col"}`；
- 非法步反馈后每步至多重试 2 次，并记入 invalid_per_move 指标。

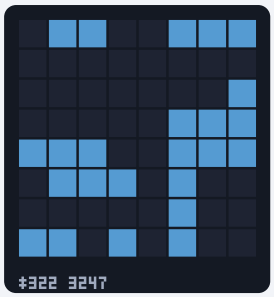
项目速览

代码规模	3435 行源码 + 1567 行测试（测试占比 31%）
运行环境	Python 3.9–3.13，零第三方依赖，克隆即跑
评测规模	11 个入库 run，累计 **8351 步**真实对局数据
开源状态	MIT · CI 双版本全绿 · Pages 在线报告 · 打包就绪

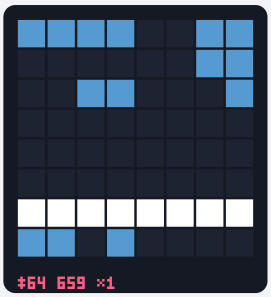
最具代表性的三个技术难点

- **确定性与可续跑的统一**——用「重放转录恢复状态」把断点续跑做成无损操作，同时成为 golden 测试的地基；
- **手写 GIF89a + LZW 编码器**——为守住零依赖承诺，自行实现图像编码，并用 Pillow 做像素级反向校验；
- **把平台故障与模型能力解耦**——三类网络故障各自机制化处理，使评测结论不被基础设施噪声污染。

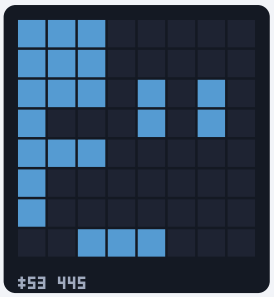
2 一张图看懂评测对象



beam 搜索基线（托盘周期精确前瞻）
单局 6141 分 / 587 步，板面始终保持低碎片化



heuristic 基线（贪心 + 板面形状特征）
单局 1142 分 / 116 步，有形状管理意识



qwen3.7-plus（LLM）最佳局 862 分 / 87 步
37 次消行 · combo×7，超过 heuristic 均值

▲ 各 Agent 实战对局 GIF 回放中的关键帧（琥珀色=新落子，底部 HUD 为步数/得分/combo）。完整动图见仓库 README 与在线报告。

3 系统架构：评测流水线

① 游戏引擎 env
19 形状库 · 放置/消除/计分纯函数 · 种子化 RNG · 不可变 Observation · 敌意输入只抛 InvalidActionError 且状态零污染

② Agent 层
random / greedy / heuristic / **beam（托盘周期精确前瞻）** / LLM（任意 OpenAI 兼容端点，urllib 实现）

③ 评测 harness
固定种子集 · 并发评测 · 非法步反馈重试 · **断点续跑 --resume** · 异常兜底不炸整轮 · JSON 转录落盘

④ 结果层
runs.jsonl 排行榜（追加式）· summary.json 聚合 · 每局完整 transcript（+LLM 对话可选）

▼ 同一份转录数据，四路消费 ▼

决策质量分析
analyze：逐步对照单步最优 → 贪心效率 / 消行把握 / 漏消次数 / 终局碎片化 / 非法步分类

GIF 回放
手写 GIF89a+LZW 编码器（≈150 行，零图像依赖），测试用 Pillow 像素级解码校验

HTML 报告
单文件（零 JS/外部资源）：排行榜 + KPI 卡片 + SVG 逐局图表，部署 GitHub Pages

inspect_ai Task
单文件适配器接入 UK AISI 官方评测框架：自定义 solver 游戏循环 + 双 scorer

关键工程决策

决策	理由与收益
零第三方依赖	克隆即跑、十年可复现；连 GIF 编码器都手写（LZW 压缩），Pillow 仅作测试期像素校验
完全确定性	同种子 + 同动作序列 ⇒ 同状态，是公平对比、断点续跑、golden 测试三件事的共同地基
非法步 = 指标	不替模型纠错，反馈后重试并记入 invalid_per_move——「指令遵循」成为一等测量维度
截断局保留分数	网络故障不丢数据；--resume 从断点无损续跑（重放转录恢复精确状态）
追加式排行榜	runs.jsonl 永不改写历史，每条成绩可溯源到完整转录与对话

生产级网络加固（实战倒逼）

对真实平台评测 15+ 小时，遭遇三类故障，全部转化为带回归测试的机制：

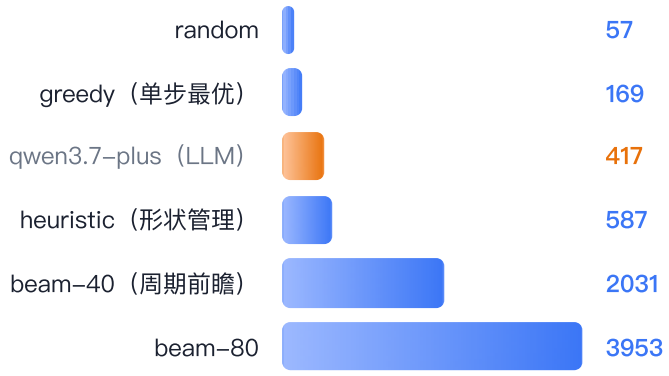
- **读超时 / 慢推理模型**
  指数退避（2s 起、60s 封顶）+ 超时自适应翻倍（600s 封顶）
- **HTTP 200 空响应体**
  定义 TransientEndpointError 瞬态错误类；harness 异常兜底，单局失败不炸整轮 10 局
- **端点级 TLS 封禁**
  诊断为网关级限流（全模型 5s 齐刷刷掐断）→ 冷却等待 + 一条命令断点续跑，零数据损失

每类故障都有**故障注入测试**（timeout / 429 / 5xx / 空 200）钉死行为。

beam 基线的核心洞察：托盘周期 = 精确搜索视界

托盘 3 块全部用完才补发、周期内 RNG 不推进 ⇒ **对当前托盘的全排列搜索是严格精确的**。BeamAgent 在该视界内做束搜索，叶子复用 heuristic 的板面特征评估。宽度 80 时均分达 heuristic 的 6.7 倍，单局突破 10140 分（1004 步）——证明该游戏天花板远未触及，也为 LLM 留下明确的能力标尺。

4 评测结果：能力阶梯



阶梯本身就是解读器：**超过 greedy ⇒ 有一步收益规划；逼近 heuristic ⇒ 有板面管理；逼近 beam ⇒ 具备跨托盘周期的长程规划**。qwen 均分 417 居 greedy 与 heuristic 之间（10 局全部自然终局），最佳单局 862 已超 heuristic 均值。

▲ 默认 10 局种子集（2024–2033）。另有 50 局大样本研究（见发现 #3）显示该种子集偏「友好」，**跨种子集分数不可直接比较**——排行榜因此始终标注种子集与配置。

#	Agent	Model	Eps	Mean	Median	Max	Moves	Lines	Combo	Inv/mv	Tok/mv
1	beam	–	10	**3953.2**	4014.5	10140	384.8	186.0	4	0.000	–
2	beam	–	10	**2031.2**	1627.0	6141	200.0	94.5	4	0.000	–
3	heuristic	–	10	**586.9**	513.0	1142	64.0	26.9	4	0.000	–
4	llm	qwen3.7-plus	10	**416.8**	405.0	862	47.6	18.9	7	0.013	7894.6
5	greedy	–	10	**169.3**	151.5	358	24.7	6.7	4	0.000	–
6	llm	qwen3.7-plus	3	**98.3**	114.0	137	11.7	4.3	2	0.029	5912.6
7	random	–	10	**56.9**	55.5	94	13.3	0.9	1	0.000	–
8	llm	GLM-5.3	3	**25.7**	25.0	47	3.0	1.0	2	0.000	4128.1

在线 HTML 报告的实时排行榜（GitHub Pages 自动部署），每行可溯源至完整对局转录

5 三个研究发现

p=1.00 | 「先推理再落子」不提升分数

项目立项要回答的问题。`--allow-reasoning` 同模型同种子对照：均分 416.8 → 446.2 看似 +7%，但因环境确定性可做**配对检验**——9 组有效配对 **5 胜 4 负、95% 置信区间 [−90, +181] 跨零、符号检验 p=1.00。+7% 完全是噪声**，median 反而降 15%。只报均值就会误判。

6.6× | 推理改善的是「自检」而非「策略」

同一实验中唯一方向明确的效应：**非法落子率 0.0126 → 0.0019（6.6 倍，Fisher p=0.059）**。即推理空间提升的是**指令遵循与空间约束自检**，不是策略深度。代价为 1.5× token。诚实标注：p=0.059 仅*接近*显著，n=9 不足以定论。

自我推翻 | 小样本让我写错过结论

曾基于 10 局数据发布「宽度 ≥20 进入高方差区」。**50 局重跑后曲线是干净单调的**（1470→1901→2329→2565），凹陷纯属抽样噪声——beam-80 标准误 n=10 时约 ±650，足以淹没 400 分真实差距。已公开修正并固化为可复现脚本。

beam 宽度敏感性（50 局/档，带标准误）

宽度	10	20	40	80
mean	1470	1901	2329	**2565**
± s.e.m.	148	263	283	291
max	4719	8834	**10740**	10140

单调递增、边际收益递减：10→20 增 432 分，40→80 仅增 236 分。小样本（10 局）曾在此出现虚假凹陷。

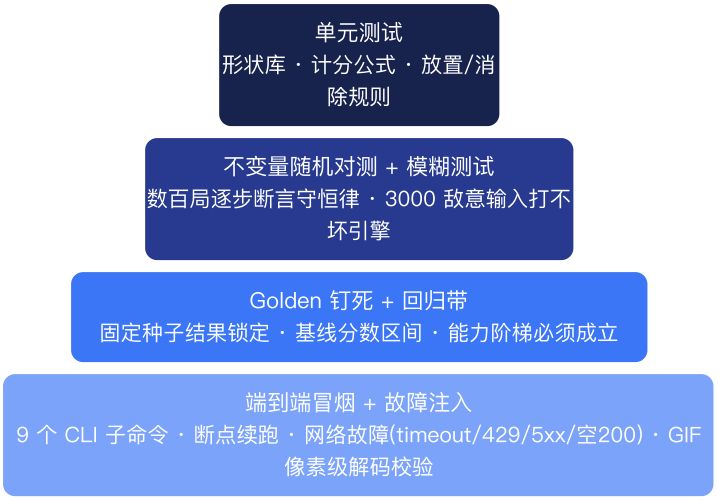


beam-80 的 run 画像卡片：KPI + 逐局得分 SVG 图表（纯内联 SVG，零 JS），万分局一目了然

发现 #4：过程指标免疫截断，结果指标不免疫

平台故障截断 6 局后用 `--resume` 补完，得到同种子对照：**均分 286.9 → 416.8（+45%）**，而**单步效率 0.954 → 0.953、消行把握 96% → 96% 几乎不动**。基础设施损耗只污染结果类指标——因此**评测报告必须公布完整终局率**，否则「模型能力弱」与「端点不稳」在数据上无法区分。这条发现也直接驱动了下方的续跑血缘设计。

6 工程质量：四层测试金字塔（107 用例，CI 双版本全绿）



两个自校验设计

- **greedy 效率恒等于 1.000**——它就是「单步最优」的定义本身，分析器一旦偏离立即报警（分析器与引擎互为校验）；
- **golden 测试跨版本验证**——Python 3.9 与 3.13 给出比特级一致的对局结果，确定性承诺有测试背书。

安全与规范

- API key 仅走环境变量；开源前两轮全历史扫描（`git grep <key> $(git rev-list --all)`）零泄漏；
- 对话存档只存 prompt/回复文本，永不落盘鉴权头。

7 交付清单

- ✓ **可运行基准**：9 个 CLI 子命令（demo/run/leaderboard/replay/gif/watch/analyze/shapes/report）
- ✓ **开源仓库**：MIT · 中英双语 README · 贡献指南 · GitHub Actions CI（3.9/3.13 矩阵）
- ✓ **在线评测报告**：GitHub Pages 单文件 HTML（排行榜/KPI 卡片/SVG 图表/GIF 回放）
- ✓ **真实评测数据**：4 档经典基线 + qwen3.7-plus 官方 10 局，全部可溯源复现
- ✓ **双框架接入**：原生 CLI + inspect_ai Task（UK AISI 官方评测框架）
- ✓ **断点续跑体系**：平台封禁期间零数据损失，解封后一条命令续跑
- ✓ **发布就绪**：wheel 构建 + 全新 venv 安装实测通过，随时可上 PyPI
- ✓ **研究产出**：能力阶梯解读法 · 消行把握率行为谱系 · 重尾指标选型结论

个人贡献与角色（独立完成）

- 游戏机制逆向与确定性环境设计、全部 Agent 与评测 harness 实现；
- 真实平台 15+ 小时评测运维：三类网络故障的诊断、加固与回归测试；
- 测试体系（107 用例）、CI、开源发布、文档与在线报告全链路。

下一步规划

- **多模型横评**：DeepSeek / GPT / Doubao 系列同种子对比，扩充排行榜；
- **推理增益实验**：--allow-reasoning（先分析后落子）vs 直出 JSON 的同种子 A/B；
- **更强上界**：MCTS / 跨周期期望搜索基线；PyPI 发布与社区成绩征集。